UNIVERSIDADE REGIONAL DE BLUMENAU

CENTRO DE CIÊNCIAS EXATAS E NATURAIS

CURSO DE CIÊNCIA DA COMPUTAÇÃO

Processamento de Linguagem Natural

2026/2

Trabalho da Unidade 3

Empregando os dados textuais obtidos por cada grupo, avaliem os resultados obtidos da combinação de diferentes representações textuais e técnicas/tarefas de Processamento de Linguagem Natural.

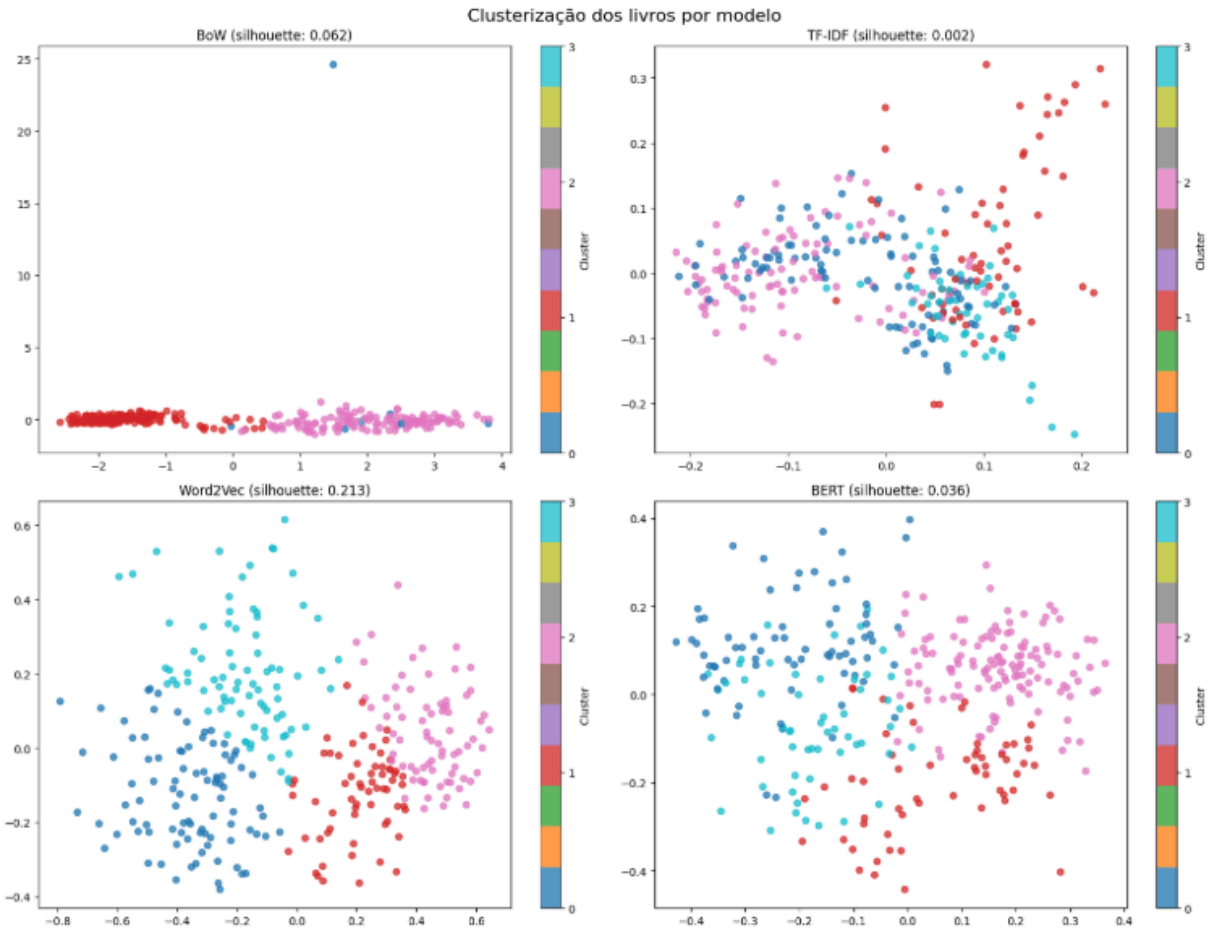
1) Iniciem marcando a lista abaixo com ✔️ para as atividades efetivamente realizadas. Se não foram realizadas, incluam uma breve justificativa (ver exemplo abaixo).

	BoW	TF-IDF	Word2Vec	BERT
Clusterização + PCA e visualização	✔️	✔️	✔️	✔️
Busca e recomendação	✔️	✔️	✔️	✔️
Classificação	✔️	✔️	✔️	✔️

Análise de sentimento	(x) Foi realizada ( ) Não foi realizada
Reconhecimento de Entidades Nomeadas	(x) Foi realizado ( ) Não foi realizado
Extração de Relações	(x) Foi realizada ( ) Não foi realizada

2) **Avaliem qualitativamente, a partir dos resultados e da leitura dos textos, qual representação gerou clusters mais representativos para os dados. Qual a quantidade de clusters que melhor expressou as características originais dos dados? Insiram imagens e interpretem as métricas intra e interclusters.**

O Word2Vec gerou a representação mais representativa para os dados, pois apresentou o maior coeficiente de silhueta como pode ser visto na imagem abaixo:



A quantidade de clusters foi fixada em 4 para 312 livros.

Analisando a métrica de silhueta (que avalia a coesão intra-cluster e a separação inter-cluster), nota-se que os valores gerais ficaram relativamente baixos (abaixo de 0.3 para todos os modelos). Isso é comum em textos longos e complexos como livros, onde há muita sobreposição de vocabulário e temas. No entanto, o Word2Vec obteve o melhor desempenho relativo, indicando uma coesão interna superior e uma separação mais nítida entre os grupos quando comparado aos outros. Ele se destacou pois ele consegue capturar a semântica e o contexto das palavras.

3) **Apresentem resultados de busca e analisem criticamente a qualidade dos top-3 e top-5 documentos retornados para cada representação. Os resultados são utilizáveis em um contexto real? Como poderiam ser combinados ou melhorados?**

Foi analisada a consulta “war politics”. A consulta é igual para as quatro representações.

Os resultados deram:

- Bow:
  - **Top-3:** 1 de 3 documentos com relevância direta; média normalizada de relevância = **0,67**.
  - **Top-5:** 2 de 5 documentos com relevância direta; média normalizada = **0,70**.
- TF-IDF:

    - **Top-3:** 1 de 3 documentos com relevância direta; média normalizada = **0,67**.
    - **Top-5:** 2 de 5 documentos com relevância direta; média normalizada = **0,70**.
- Word2Vec:
    - **Top-3:** 0 de 3 documentos com relevância direta; média normalizada = **0,50**.
    - **Top-5:** 0 de 5 documentos com relevância direta; média normalizada = **0,30**.
- BERT / MiniLM:
    - **Top-3:** 2 de 3 documentos com relevância direta; média normalizada = **0,83**.
    - **Top-5:** 2 de 5 documentos com relevância direta; média normalizada = **0,70**.

Com esses resultados, podemos chegar a conclusão que eles não seriam os mais adequados para realizar uma busca. Principalmente para um termo genérico como “war politics”.

Para melhorar esses resultados, poderiam ser adicionados mais termos a fim de especificar a busca e filtrar os livros.

Além disso, possivelmente a aplicação de uma busca híbrida com TF-IDF ou Bow com o BERT poderia resultar em melhores buscas. O RRF poderia juntar os resultados das duas buscas considerando a posição de cada livro em cada lista. Se o livro estivesse bem colocado nas duas listas, receberia mais pontos.

4) **Foi possível treinar um classificador? Como ele se comportou a partir de dados novos? Alguma representação textual favorece classificações mais precisas? Quais? Foi utilizada alguma técnica utilizando modelos de linguagem ou de modelos de decisão? Explique.**

Foi possível treinar um classificador, por meio da regressão logística foram utilizados 75% dos livros para treinamento e 25% para teste. Em um geral, com os dados novos, ou seja não classificados, ele conseguiu classificar os livros com seus respectivos gêneros.

Dentre as representações, o TF-IDF foi o mais eficiente na tarefa, com 0,62 de acurácia e 0,41 de F1 Macro. Já o Word2Vec teve uma acurácia bem menor com 0,04 e F1 Macro de 0,01. Seu resultado foi diferente em relação a clusterização por conta da divisão dos livros.

A clusterização utilizou 312 livros (com e sem a definição dos gêneros) para agrupar os dados. Em contrapartida, a classificação foi supervisionada e utilizou 218 livros com seus gêneros rotulados definidos para treinar e medir a acurácia e o F1 dos resultados. Portanto, a clusterização funcionou bem para encontrar padrões gerais no conjunto total, enquanto a classificação avaliou a separação de classes específicas com base nos rótulos conhecidos de uma amostra menor.

Por fim, foram utilizadas técnicas de representação textual e um algoritmo de classificação:

- O modelo Transformer (MiniLM) pré-treinado transforma cada resumo em um vetor de 384 números que representa informações do texto. Nessa situação, ele foi utilizado para gerar representações, sem realizar um novo treinamento do Transformer.

- A Regressão Logística foi o modelo de decisão usado para classificar os livros nas quatro abordagens. Ele aprende com os vetores e os gêneros conhecidos no treinamento quais padrões ajudam a prever o gênero de um livro novo.

-

5) **Análise de sentimentos, Extração de Entidades Nomeadas e Extração de Relações são aplicáveis aos dados coletados? Em caso positivo, que tipo de resultado foi obtido?**

Sim. As técnicas de análise de sentimentos, extração de entidades nomeadas e extração de relações são aplicáveis aos dados do Projeto Gutenberg.

A análise de sentimentos foi realizada utilizando o modelo distilbert/distilbert-base-uncased-finetuned-sst-2-english, que classifica os textos em duas categorias: POSITIVE e NEGATIVE, retornando também um nível de confiança para cada classificação. Foram utilizadas as sinopses dos livros, cujos resultados apresentaram predominância de classificações positivas. Entretanto, em diversos casos, os resultados pareceram inconsistentes com o conteúdo das obras, como livros relacionados a vingança, assassinato e mistério classificados como POSITIVE. Essa limitação pode estar relacionada ao uso de sinopses, que nem sempre expressam diretamente o sentimento predominante da narrativa. Como possibilidade de melhoria, propõe-se corrigir a base de dados e utilizar trechos maiores dos livros. Inicialmente, apenas 15 trechos estavam válidos para análise, o que levou à escolha das sinopses para ampliar a quantidade de textos avaliados.

A extração de entidades nomeadas (NER) foi realizada com o modelo dslim/bert-base-NER, com o objetivo de identificar entidades mencionadas nos textos. Entre os resultados, foram identificados nomes de personagens, como Elizabeth, Ishmael e Pinocchio, além de nomes associados aos autores, como Dostoevsky. Entretanto, foram observadas limitações, incluindo possíveis classificações incorretas e a repetição de entidades em diferentes obras. A ocorrência de nomes como Elizabeth em livros distintos pode dificultar a identificação de personagens únicos quando os resultados são analisados sem considerar o título e o identificador do livro. Além disso, o modelo não foi desenvolvido especificamente para textos literários, o que pode afetar a precisão das identificações. Assim, embora a técnica seja aplicável, seus resultados precisam ser avaliados considerando o contexto das obras.

A extração de relações foi realizada utilizando o modelo REBEL, com o objetivo de identificar relações entre entidades presentes nas sinopses dos livros. Os resultados foram organizados em triplas compostas por sujeito, relação e objeto. Ao todo, foram extraídas 69 relações, incluindo informações como data de publicação, período de produção da obra e gênero literário. Entretanto, os resultados apresentaram limitações, como relações pouco relacionadas ao conteúdo narrativo e a identificação de informações bibliográficas em vez de relações entre personagens. Isso indica que, embora a técnica seja aplicável ao conjunto de dados, sua efetividade depende da qualidade dos textos utilizados e da capacidade do modelo de interpretar adequadamente o contexto literário.

6) **As técnicas estudadas auxiliam na concretização do projeto apresentado na Unidade 1? Expliquem.**

As técnicas estudadas auxiliam diretamente na concretização do projeto, porque ele envolve coletar textos literários, prepará-los para análise e utilizar suas características textuais para identificar gêneros literários.

Os conceitos de PLN ajudam a entender como o computador pode interpretar os textos e também permitem organizar o projeto em etapas, desde a obtenção dos textos até a classificação dos gêneros. Depois da coleta, técnicas como limpeza, normalização, tokenização e remoção de stopwords ajudam a preparar os textos para a análise, reduzindo ruídos e organizando os dados para as próximas etapas.

Para classificar os gêneros literários, é necessário transformar os textos em representações que os algoritmos consigam processar. Técnicas como Bag of Words e TF-IDF permitem representar palavras por meio de valores numéricos, enquanto os word embeddings permitem representar palavras considerando relações entre seus significados.

Instruções gerais:

- O código e os resultados devem ser inseridos em pasta específica do repositório indicado em trabalhos anteriores.
- As respostas 2, até 6, acima, deverão ser apresentadas em formato de texto descritivo/argumentativo, sempre que possível amparados por figuras, exemplos dos dados, resultados e trechos de código.
- Para testes de implementação das técnicas, é permitido o uso de amostragens menores dos dados obtidos, desde que explicitado.
- **É permitido o uso auxiliar de IA generativa, desde que indicado explicitamente o fornecedor/modelo e prompts utilizados.**